

## PROGRAMA DE MATERIA

### DATOS GENERALES

<b>Nombre de la unidad de aprendizaje:</b>	Orientación A1 En Inteligencia Artificial y Ciencia de los Datos Arquitectura de Sistemas de IA				
<b>Clave:</b>	V2225				
<b>Créditos:</b>	8				
<b>Área de formación:</b>	Especializante selectiva				
<b>Tipo de curso:</b>	Curso-taller				
<b>Prerrequisito:</b>					
<b>Departamento:</b>	Depto. de Innovación Tecnológica				
<b>Academia:</b>					
<b>Total de Carga Horaria:</b>	80	<b>Horas Teoría</b>	40	<b>Horas Práctica</b>	40
<b>Nivel de formación:</b>	Licenciatura				
<b>Programa(s) educativos</b>	Licenciatura en Inteligencia Artificial y Ciencia de Datos				

### PRESENTACIÓN

La IA ya no vive solo en cuadernos de experimentación: opera en productos y servicios que dependen de datos confiables, entrenamiento reproducible y despliegues controlados. La adopción empresarial sigue en ascenso —el 78% de las organizaciones declara usar IA en al menos una función— y, al mismo tiempo, el costo de inferencia cae de forma drástica, lo que acelera los casos de uso y exige decisiones arquitectónicas mejor fundamentadas sobre pipelines, almacenamiento, escalabilidad y monitoreo (McKinsey, 2025; Stanford HAI AI Index, 2025).

Este curso aporta al perfil profesional la capacidad de pensar en sistemas: seleccionar patrones (batch/online), documentar calidad de datos, comparar algoritmos —incluido aprendizaje profundo— con métricas pertinentes y conectar el modelo con infraestructura mediante contenedores, registro de artefactos, observabilidad y control de riesgos. Con ello, las y los estudiantes aprenden a diseñar y evaluar arquitecturas que equilibran rendimiento, costo y responsabilidad, en un entorno donde los modelos son cada vez más potentes y las decisiones de plataforma determinan su valor real (Stanford HAI AI Index, 2025).

### BLOQUE DEL MODELO CURRICULAR CUGDL

Bloque de especialización. Corresponde al Área de Formación Especializante Selectiva. La finalidad es ofrecer oportunidades para profundizar o ampliar los conocimientos, tanto dentro de la profesión elegida como en campos relacionados. En este bloque se articulan unidades de aprendizaje para el desarrollo de competencias específicas vinculadas a ámbitos del ejercicio profesional.

## COMPETENCIAS GENÉRICAS DEL PERFIL DE EGRESO CON LA QUE SE VINCULA

Diseñar arquitecturas tecnológicas avanzadas de ciencia de datos e inteligencia artificial para solucionar problemas reales complejos de forma efectiva y multidisciplinaria con un sentido creativo y ético.

Desarrollar arquitecturas tecnológicas avanzadas de ciencia de datos e inteligencia artificial para solucionar problemas reales complejos de forma efectiva y multidisciplinaria con un sentido creativo y ético.

## RESULTADOS DE APRENDIZAJE

Analizar componentes y patrones de arquitectura de IA para explicar la relación datos–modelo–servicios y sus implicaciones de calidad y costo.

Diseñar tuberías de datos y entrenamientos reproducibles mediante elecciones informadas de algoritmos, marcos de trabajo y criterios de validación.

Integrar modelos (incluido aprendizaje profundo) en aplicaciones definiendo interfaces, almacenamiento, escalabilidad y observabilidad.

Evaluar riesgos, sesgos y cumplimiento para proponer mejoras de transparencia, rendimiento y ética en sistemas de IA.

## CONTENIDO DE LA ASIGNATURA

UNIDAD 1.	Fundamentos y componentes de sistemas de IA	Número de semanas	4 semanas
Resultados de aprendizaje esperados	Analizar componentes y patrones de arquitectura de IA para explicar la relación datos–modelo–servicios y sus implicaciones de calidad y costo.		
1.1. Arquitectura general de sistemas de IA: capas de datos, modelo y consumo. 1.2. Componentes clave: conjuntos de datos, características, modelos, artefactos y <i>registries</i> . 1.3. Calidad de datos: sesgos de muestreo, <i>data drift</i> , validación y documentación. 1.4. Taxonomía de tareas y algoritmos: supervisado, no supervisado y PLN/visión. 1.5. Criterios de selección de algoritmos y métricas por tarea. 1.6. Patrones de arquitectura: <i>batch/stream, offline/online, feature stores</i> .			
Evidencias de logro de resultados de aprendizaje	<ul style="list-style-type: none"><li>E1.1 Documento de arquitectura conceptual (contexto, componentes, flujos y supuestos).</li><li>E1.2 Especificación de calidad de datos (esquema, validaciones, riesgos y métricas).</li></ul>		

UNIDAD 2.	Diseño de datos y entrenamiento reproducible	Número de semanas	4 semanas
Resultados de aprendizaje esperados	Diseñar tuberías de datos y entrenamientos reproducibles mediante elecciones informadas de algoritmos, marcos de trabajo y criterios de validación.		
2.1. Diseño y gestión de <i>datasets</i> : particiones, etiquetado y <i>versionado</i> . 2.2. Entrenamiento y validación: <i>hold-out</i> , <i>k-fold</i> , curvas de aprendizaje y <i>early stopping</i> . 2.3. Algoritmos base: regresión, árboles/ensembles; comparación y <i>baselines</i> . 2.4. Arquitecturas de aprendizaje profundo: CNN, RNN y Transformers (nociones comparadas). 2.5. <i>Experiment tracking</i> y gestión de artefactos; reproducibilidad y <i>seeds</i> . 2.6. Evaluación y <i>model cards</i> : métricas, límites, riesgos y requisitos de uso.			
Evidencias de logro de resultados de aprendizaje	<ul style="list-style-type: none"><li>E2.1 Protocolo de entrenamiento y validación con <i>tracking</i> y <i>baselines</i>.</li><li>E2.2 Informe comparativo de algoritmos/arquitecturas con métricas y <i>model card</i>.</li></ul>		

UNIDAD 3.	Integración, despliegue y escalabilidad	Número de semanas	4 semanas
Resultados de aprendizaje esperados	Integrar modelos (incluido aprendizaje profundo) en aplicaciones definiendo interfaces, almacenamiento, escalabilidad y observabilidad.		
3.1. Exposición de modelos: lotes vs. servicios en línea; APIs y <i>batch scoring</i> . 3.2. Almacenamiento y entrega: <i>feature store</i> , <i>model registry</i> , <i>artifact store</i> . 3.3. Despliegue y escalado: contenedores, <i>autoscaling</i> , <i>A/B testing</i> y <i>canary releases</i> . 3.4. Observabilidad de IA: <i>monitoring</i> , <i>drift detection</i> , <i>alerting</i> y <i>rollbacks</i> . 3.5. Integración en sistemas existentes: <i>orchestration</i> y dependencias.			
Evidencias de logro de resultados de aprendizaje	<ul style="list-style-type: none"><li>E3.1 Diseño técnico de despliegue (diagrama de servicios, almacenamiento y monitoreo).</li><li>E3.2 Tablero de indicadores propuesto (rendimiento, costo, estabilidad y <i>drift</i>).</li></ul>		

UNIDAD 4.	Ética, transparencia y tendencias en IA	Número de semanas	4 semanas
Resultados de aprendizaje esperados	Evaluar riesgos, sesgos y cumplimiento para proponer mejoras de transparencia, rendimiento y ética en sistemas de IA.		
4.1. Riesgos y sesgos en datos y modelos; impacto y mitigación.			
4.2. Transparencia e interpretabilidad: documentación, <i>explainability</i> (nociones) y auditoría.			
4.3. Cumplimiento y normas: privacidad, seguridad y responsabilidad del diseño.			
4.4. Tendencias en arquitecturas de IA y adopción tecnológica.			
Evidencias de logro de resultados de aprendizaje	<ul style="list-style-type: none"><li>E4.1 Evaluación de riesgos y plan de mitigación (sesgos, privacidad, seguridad).</li><li>E4.2 Revisión arquitectónica final con recomendaciones de mejora y <i>roadmap</i>.</li></ul>		

## METODOLOGÍA DE ENSEÑANZA PARA PROMOVER EL APRENDIZAJE

Métodos propuestos	Actividades básicas presenciales	Actividades en moodle
Aprendizaje basado en proyectos con portafolio por hitos U1–U4, aula invertida para conceptos y taller para construcción de artefactos (diagramas, protocolos, informes); retroalimentación formativa y coevaluación con rúbricas.	Sesiones de conceptos clave, clínicas de diseño y revisiones de arquitectura.	Micro lecturas/cuestionarios; foros de decisiones; entrega de evidencias; rúbricas y seguimiento de hitos.

## LABORATORIO Y SOFTWARE

USO DE LABORATORIO	
Necesidades de Software y Equipamiento	

## EVALUACIÓN

Evidencia	Porcentaje
Hito 1 (U1): Arquitectura conceptual + especificación de calidad de datos	20%
Hito 2 (U2): Protocolo de entrenamiento/validación + informe comparativo	25%
Hito 3 (U3): Diseño de despliegue + tablero de indicadores	25%
Hito 4 (U4): Evaluación de riesgos + revisión arquitectónica final	20%
Participación y verificaciones en Moodle	10%

## BIBLIOGRAFÍA

Básica
Bass, L., Lu, Q., Weber, I., & Zhu, L. (2025). <i>Engineering AI Systems: Architecture and DevOps Essentials</i> . Addison-Wesley Professional. ISBN 978-0138261412.

Disponible en

<https://www.amazon.com/Engineering-AI-Systems-Architecture-Essentials/dp/0138261415>

Bernstein, P. (2022). *Machine Learning: Architecture in the Age of Artificial Intelligence*. RIBA Publishing. ISBN 978-1914124013. Disponible en

<https://www.amazon.com/Machine-Learning-Architecture-Artificial-Intelligence/dp/1914124014/> ([amazon.com](https://www.amazon.com/))

Tranquillin, M., Lakshmanan, V., & Tekiner, F. (2023).

*Architecting Data and Machine Learning Platforms*. O'Reilly Media. ISBN 978-1098151607.

Disponible en <https://www.oreilly.com/library/view/architecting-data-and/9781098151607/>

Martínez, D. R., & Kifle, B. M. (2024). *Artificial Intelligence: A Systems Approach from Architecture Principles to Deployment*. MIT Press. ISBN 978-0262048981. Disponible en

<https://www.amazon.com/Artificial-Intelligence-Architecture-Principles-Deployment/dp/0262048981/> ([amazon.com](https://www.amazon.com/))

Calcagno Lucares, W. E. (2024). *Arquitectura e ingeniería de datos* [en español]. Anaya Multimedia. ISBN 978-84-415-4970-8. Disponible en

<https://anayamultimedia.es/libro/manuales-imprescindibles/arquitectura-e-ingenieria-de-datos-walter-e-calcagno-lucares-9788441549708/>

#### Complementaria

Narayanan, A., & Kapoor, S. (2024). *AI Snake Oil: What Artificial Intelligence Can Do, What It Can't, and How to Tell the Difference*. Princeton University Press. ISBN 978-0691249131.

Disponible en <https://www.amazon.com/AI-Snake-Oil-Artificial-Intelligence/dp/0691249131/> ([amazon.com](https://www.amazon.com/))

Hsieh, W., Bi, Z., Jiang, C., Liu, J., Peng, B., Zhang, S., et al. (2024). *A Comprehensive Guide to Explainable AI: From Classical Models to LLMs*. Springer. ISBN consultable. Disponible en

<https://arxiv.org/abs/2412.00800>

#### Perfil del Profesorado

- Formación mínima: IA, Ciencia de Datos, Computación o afín.
- Experiencia (general): diseño de arquitecturas y *pipelines* de IA, entrenamiento y evaluación de modelos (incluido DL), despliegue y monitoreo; criterios éticos y de transparencia.

### APROBACIÓN DEL PROGRAMA

Autores del programa	Fecha de elaboración	Fecha de visto bueno Secretaría Académica



Revisores del programa	Fecha de revisión	Porcentaje de ajuste	Fecha de visto bueno Secretaría Académica